

Modelagem Informacional

Aula 05 – Modelagem Multidimensional: Fatos, Dimensões,
Star Schema e Snowflake Schema

Prof. Dr. Wagner de A. Perin

A Virada de Chave: Do Operacional para o Analítico

Onde Estávamos (Aulas 03 e 04):

Modelagem Relacional Transacional (*OLTP*) em 3ª Forma Normal (3FN).

- Foco absoluto em **eliminar redundâncias**, garantir consistência **ACID** e evitar anomalias de atualização.

O Desafio de Hoje:

- Por que a 3FN "morre" ao tentar responder perguntas analíticas em bases com **bilhões** de linhas?
- Como desnormalizar de forma estruturada e controlada para acelerar relatórios executivos?

Problema Investigado: Como arquitetar bases de dados analíticas capazes de responder a **cruzamentos complexos** em segundos **sem derrubar a operação da empresa?**

Objetivos da Aula

O que você dominará ao final desta aula?

1. **Distinguir** com clareza os requisitos e objetivos dos ambientes **OLTP** vs. **OLAP**.
2. **Aplicar** os 4 passos metódicos do *Design Dimensional* de **Ralph Kimball**.
3. **Definir** a granularidade correta e classificar métricas (aditivas, semi-aditivas e não-aditivas).
4. **Avaliar** os *trade-offs* arquiteturais entre **Star Schema** e **Snowflake Schema**.
5. **Construir e consultar** um *Data Mart* em SQL utilizando **Surrogate Keys** e operações analíticas (*Slice, Dice, Roll-up, Drill-down*).

Fundamentos & Metodologia

Da Teia Relacional ao Manifesto de *Ralph Kimball*

Prof. Dr. Wagner de A. Perin

A Dor de Negócio no Varejo Omnichannel

Problema Investigado:

*O Diretor Comercial da **MegaRetail** solicitou um relatório de faturamento cruzando os últimos 5 anos por categoria, região e trimestre para planejar o orçamento anual.*

O Colapso Operacional:

1. A consulta gerou **12 JOINS** no banco relacional do ERP (3FN).
2. **Tempo de execução**: 42 minutos consumindo 100% de CPU.
3. **Impacto Imediato**: Travamento dos caixas das lojas físicas e interrupção na emissão de cupons fiscais em horário de pico.



A Armadilha do Produto Cartesiano (Explosão Combinatória)

A matemática por trás do colapso do servidor

- **Definição Matemática e Relacional:** O Produto Cartesiano ($R \times S$) gera todas as combinações possíveis entre duas relações, onde $|R \times S| = |R| \times |S|$.
- **O Pesadelo Prático em Big Data:**
 - Tabela de Vendas (1.000.000 linhas) x Tabela de Clientes (100.000 linhas).
 - **Resultado:** (100 bilhões de registros) gerados na memória/disco.
- **O que acontece com o servidor de banco de dados:**
 - Esgotamento imediato do *buffer pool*.
 - *Spill to disk* (swapping massivo limitando I/O).
 - Travamento do servidor e erro crítico de estouro de memória (**Out Of Memory - OOM**).

Álgebra Relacional: Produto Cartesiano vs. Junção ($\bowtie$)

A teoria por trás da otimização de consultas

- **Abordagem Ingênua (Produto Cartesiano Filtrado):**
 - $\sigma_{\text{condição}}(R \times S)$
 - O SGBD gera todas as combinações primeiro para depois filtrar. Totalmente ineficiente.
- **Junção Relacional Otimizada (*Theta-Join / Equi-Join*):**
 - $R \bowtie_{\text{condição}} S$
 - Cruza apenas registros correspondentes via algoritmos como Índices, Hash Join ou Merge Join.
- **A Sintaxe SQL:**
 - **Legada e Perigosa:** FROM Vendas, Clientes WHERE ... (Fácil esquecer o filtro e explodir o banco).
 - **Moderna (ANSI):** FROM Vendas JOIN Clientes ON ...

Álgebra Relacional: Produto Cartesiano vs. Junção ($\bowtie$)

A teoria por trás da otimização de consultas

- **Abordagem Ingênua (Produto Cartesiano Filtrado):**
 - $\sigma_{\text{condição}}(R \times S)$
 - O SGBD gera todas as combinações primeiro para depois filtrar. Totalmente ineficiente.
- **Junção Relacional Otimizada (*Theta-Join / Equi-Join*):**
 - $R \bowtie_{\text{condição}} S$
 - Cruza apenas registros correspondentes via algoritmos como Índices, Hash Join ou Merge Join.
- **A Sintaxe SQL:**
 - **Legada e Perigosa:** FROM Vendas, Clientes WHERE ... (Fácil esquecer o filtro e explodir o banco).
 - **Moderna (ANSI):** FROM Vendas JOIN Clientes ON ...
- **Pausa para Demonstração**

Por que a Sintaxe ANSI SQL **JOIN ... ON** Salva Vidas e Orçamentos?

Separação de responsabilidades na engenharia de *queries*

- **Separação Estrita de Lógicas:**
 - **Lógica de Conexão de Dados:** Define como as tabelas se relacionam (**ON** `f.id_cliente = c.id_cliente`).
 - **Lógica de Filtro de Negócio:** Define o recorte de dados de interesse (**WHERE** `c.estado = 'SP'`).
- **Segurança contra Falhas Humanas:**
 - Evita o esquecimento acidental de predicados de junção (que transforma uma query inofensiva em um produto cartesiano inadvertido).
- **Otimizador de Consultas (*Query Optimizer*):**
 - Facilita a geração de Planos de Execução eficientes pelo SGBD. Comprove usando **EXPLAIN ANALYZE**.

O Confronto dos Paradigmas: OLTP vs. OLAP

Por que precisamos de dois mundos separados?

Característica	<i>OLTP</i> (Operacional / Transacional)	<i>OLAP</i> (Analítico / <i>Data Warehouse</i>)
Propósito Principal	Registrar transações diárias do negócio	Suportar tomada de decisão estratégica
Operação Dominante	Escritas rápidas (<i>INSERT</i> , <i>UPDATE</i>)	Leituras massivas e agregações (<i>SUM</i> , <i>AVG</i>)
Normalização	3ª Forma Normal (3FN - Sem redundância)	Desnormalizado (<i>Star</i> / <i>Snowflake Schema</i>)
Volume de Dados	Dados correntes (tempo real / meses)	Histórico acumulado de anos
Público Usuário	Sistemas, caixas, atendentes, clientes	Cientistas de Dados, Analistas de BI, C-Level

O Manifesto de Ralph Kimball

A Filosofia da Modelagem Dimensional


Ralph Kimball revolucionou a Engenharia de Dados ao propor que os dados analíticos devem ser modelados para **simplicidade e velocidade**:

1. **Performance Máxima**: Reduzir drasticamente a quantidade de **JOINS** necessários para responder a uma consulta de negócio.
2. **Compreensibilidade Imediata**: O modelo reflete a forma como os gestores pensam sobre o negócio (*Quem, Onde, Quando, O Quê*).
3. **Aderência Nativa a BI**: Otimizado para motores colunares e ferramentas de visualização (*Power BI, Tableau, Looker*).

Insight Executivo: Em *Analytics*, redundância controlada de atributos descritivos não é pecado: é otimização de custo de processamento.

Os 4 Passos do Design Dimensional de Kimball

A Metodologia Padrão de Mercado



1. **Processo de Negócio:** O evento operacional que gera dados (ex: *Vendas no Caixa, Emissão de Apólices, Cliques no App*).
2. **Granularidade (O Grão):** O que representa exatamente UMA linha na tabela fato?
3. **Dimensões:** O contexto qualitativo que descreve o evento (*Quem comprou? Onde? Quando? Qual produto?*).
4. **Fatos:** Os números e valores quantitativos gerados no evento (*Quanto faturou? Quantas unidades? Qual desconto?*).

O Conceito Fundamental de Granularidade

O Grão: A Decisão mais Crítica do Projeto

Regra de Ouro de Kimball: Sempre declare a **Granularidade Atômica** mais detalhada possível antes de escolher dimensões ou fatos!

Exemplos de Grãos em Vendas:

- **Grão Atômico:** *Um item individual vendido em uma linha de cupom fiscal em um caixa. (Permite responder a qualquer pergunta futura).*
- **Grão Agregado:** *Total vendido por loja por dia. (Impede saber que horas vendeu ou quais itens foram comprados juntos).*

Atenção: Uma vez fixado o grão, **todas as métricas da tabela fato devem pertencer estritamente àquele mesmo grão**. Misturar grãos diferentes na mesma fato gera duplicação matemática!

Anatomia da Tabela Fato: Tipos de Métricas

Nem todo número pode ser somado da mesma forma!

As métricas numéricas armazenadas nas tabelas fato dividem-se em 3 categorias vitais:

1. **Fatos Aditivos:**

- Podem ser somados através de todas as dimensões (*Tempo, Loja, Produto*).
- *Exemplos:* quantidade_vendida, valor_total_item, custo_frete.

2. **Fatos Semi-aditivos:**

- Podem ser somados em algumas dimensões, mas NÃO no Tempo.
- *Exemplos:* saldo_estoque_diario, saldo_bancario_fechamento (Somar o saldo de 30 dias não gera o saldo do mês!).

3. **Fatos Não-aditivos:**

- **Não podem ser somados** diretamente em nenhuma dimensão.
- *Exemplos:* margem_lucro_percentual, desconto_percentual, preco_unitario.
- *Solução:* Armazenar os componentes (valor_lucro e valor_venda) e recalcular a divisão na *query* analítica.

O Contexto Rico do Negócio

As dimensões contêm os atributos textuais e descritivos usados para **filtrar, agrupar e rotular** os relatórios:

- **Dimensão Tempo:** Não use apenas `TIMESTAMP`. Inclua colunas explícitas como: `ano`, `trimestre`, `mes`, `nome_mes`, `dia_semana`, `eh_fim_de_semana`, `eh_feriado`.
- **Dimensão Produto:** `sku`, `nome_produto`, `categoria`, `subcategoria`, `marca`, `tamanho`, `cor`.
- **Dimensão Cliente:** `cpf`, `nome`, `faixa_etaria`, `genero`, `cidade`, `estado`, `regiao`.
- **Dimensão Loja:** `cod_filial`, `nome_loja`, `tipo_canal` (Física / E-commerce), `cidade`, `gerente_regional`.

Característica Chave: Tabelas de dimensão são largas (muitas colunas), ricas em texto e possuem poucas linhas comparadas à tabela fato.

Chaves no Data Warehouse: Surrogate Keys vs. Natural Keys

Por que **NUNCA** usar a chave do **ERP como PK no DW?**


- **Natural Key** (Chave de Negócio): O identificador gerado pelo sistema de origem (ex: *CPF do cliente, SKU do produto, CNPJ*).
- **Surrogate Key** (Chave Substituta): Um número inteiro sequencial (*INT / BIGINT*) gerado exclusivamente dentro do *Data Warehouse* (ex: *sk_cliente = 1042*).

Vantagens Cruciais da Surrogate Key:

- **Desempenho de JOIN:** Comparar inteiros de 4 bytes na CPU é ordens de grandeza mais rápido que comparar *Strings* (ex: *UUIDs ou CPFs*).
- **Isolamento de Origem:** Se o ERP for trocado por outro fornecedor ou alterar a tipagem do código, o *Data Warehouse* não sofre quebra.
- **Rastreamento Histórico (SCD):** Permite que o mesmo cliente tenha duas linhas na dimensão quando mudar de endereço, mantendo o histórico de vendas intacto.

Star Schema vs. Snowflake Schema

A Batalha das Arquiteturas Multidimensionais



- **Star Schema:** Dimensões 100% desnormalizadas. Apenas **1 JOIN** por dimensão. Padrão ouro para BI.
- **Snowflake Schema:** Dimensões normalizadas em níveis hierárquicos. Economiza espaço, mas penaliza a velocidade e complica o *DAX/SQL*.

Laboratório Prático & PBL

Construção e Exploração do *Star Schema* da *MegaRetail*

Prof. Dr. Wagner de A. Perin

FUCAPE

B U S I N E S S S C H O O L