FUCAPE
BUSINESS SCHOOL

Arquiteturas Modernas de Repositórios e Processamento de Dados

Modelagem Informacional

Prof. Dr. Wagner Perin
Graduação em Ciência de Dados para Negócios

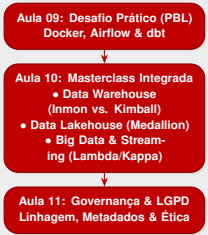
Onde Estamos na Jornada? Visão Panorâmica da Aceleração

Bimestre 1 (Fundamentos & Execução Tática):

- Modelagem Relacional & Normalização (1FN, 2FN, 3FN).
- Paradigmas ELT vs. ETL e Idempotência matemática.
- **Aula 09:** Pipelines com Docker, Airflow e `dbt`.

Aceleração Estratégica (Aula 10 — 2º Bimestre):

- **Salto Epistemológico:** Do pipeline local para o **Desenho de Arquitetura Corporativa**.
- **Foco Conceitual & Decisório:** Sem código; foco em trade-offs de negócio e C-Level.



INSIGHT EXECUTIVO

Insight Executivo: Um engenheiro sabe ligar os canos; um estrategista de negócios sabe **quais reservatórios construir**!

O Caso Omnivita Saúde & FinTech: O Colapso dos 3 Mundos



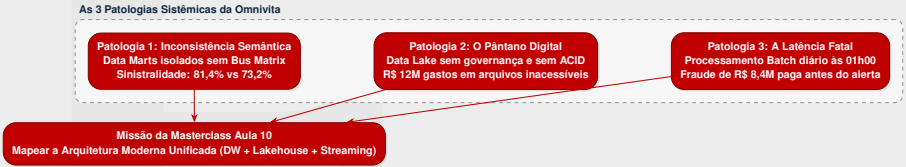
Crise Decisória no Conselho de Administração

*Holding de **R$ 2,8 bilhões/ano**, 2,2M de vidas e 45 hospitais em crise decisória.*

As 3 Crises Simultâneas no Conselho:

1. **Guerra dos Números (Silos):**
   - Diretoria Médica: **81,4%** de sinistralidade.
   - CFO (Finanças): **73,2%** de sinistralidade.
   - Silos com regras conflitantes travaram dividendos!
2. **Pântano de Dados (R$ 12 Milhões):**
   - Object Storage sem ACID, catálogo ou governança.
   - Falhas constantes por arquivos corrompidos.
3. **Fraude Noturna de R$ 8,4 Milhões:**
   - 18 clínicas fantasmas faturaram no feriado.
   - O lote diário só rodou na terça: liquidação cega!

Diagnóstico Analítico & Dilemas de Arquitetura: As 3 Patologias



Dilemas de Arquitetura & Decisão Analítica:

- *Se todos consultavam o mesmo banco de dados relacional, como dois diretores chegaram a números tão discrepantes?*
- *Por que armazenar terabytes na nuvem pagando centavos de storage tornou-se um passivo de R$ 12M?*
- *Por que a esteira Airflow da Aula 09 foi matematicamente incapaz de deter a fraude no feriado?*

O Que É (e o que NÃO É) um Data Warehouse Moderno?

*"Um Data Warehouse é uma coleção de dados orientada por assunto, integrada, não volátil e variável no tempo, cujo propósito é apoiar as decisões da gestão." — **Bill Inmon (1992)***

Dimensão Crítica	Banco Transacional (OLTP)	Data Warehouse (OLAP)
Foco Primário	Operação diária rápida (venda, checkout)	Análise histórica profunda e tomada de decisão
Padrão de Consulta	Leituras e escritas atômicas em 1 linha (`PK`)	Agregações massivas em milhões de linhas (`SUM/AVG`)
Volatilidade	Altamente volátil (`UPDATE` / `DELETE` constantes)	Não volátil (apenas cargas de inserção histórica)
Modelagem Ideal	3ª Forma Normal (3FN) para evitar anomalias	Esquemas Dimensionais Desnormalizados (*Star Schema*)

Armadilha de Mercado: *Ligar ferramentas de BI diretamente no banco transacional de produção (ERP/CRM) causa travamento do sistema operacional. O DW existe para **desacoplar o fardo analítico da operação diária**!*

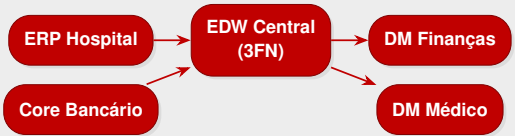
A Batalha dos Gigantes I: Bill Inmon (Top-Down / CIF)

Filosofia & Arquitetura:

- *Corporate Information Factory (CIF)*: Construção centralizada **Top-Down** em 3FN atômica.
- **Metáfora:** Arranha-céu de 80 andares — as fundações corporativas precisam estar 100% prontas antes de inaugurar qualquer sala.

Mecânica Operacional:

1. Sistemas legados alimentam o **EDW Central**.
2. EDW modelado estritamente na **3FN**.
3. Derivação de *Data Marts* dependentes.



Trade-Off Executivo: *Máxima consistência, porém* ***Time-to-Value inaceitável*** *(2 a 3 anos de projeto). As demandas mudam antes da entrega!*

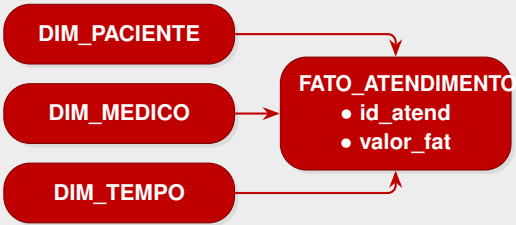
A Batalha dos Gigantes II: Ralph Kimball (Bottom-Up / DDW)

Filosofia & Agilidade:

- *Dimensional DW (DDW)*: Construção **Bottom-Up** orientada por processos de negócio.
- **Metáfora:** Bairros planejados modulares conectados por avenidas centrais padronizadas.

Mecânica Arquitetural:

- O DW é a união dos Data Marts em **Star Schemas** (Fatos e Dimensões).
- Entregas rápidas de valor a cada 6 a 8 semanas.
- Foco total em usabilidade para analistas de BI.



INSIGHT EXECUTIVO

Insight Executivo: Kimball venceu o mercado porque diretores exigem valor rápido no trimestre, não promessas de 3 anos!

A Salvação da Omnivita: Bus Matrix & Dimensões Conformadas

- **A Raiz do Conflito 81,4% vs. 73,2%:** Finanças olhou a *data de pagamento contábil*; Médica olhou a *data da cirurgia*.
- **A Solução Canônica:** *Enterprise Bus Matrix* com dimensões conformadas compartilhadas por múltiplos processos.

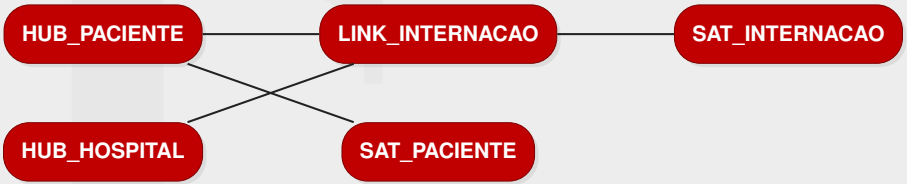
Processos de Negócio (Fatos)	Dim_Paciente	Dim_Hospital	Dim_Tempo (Cirurgia)	Dim_Data_Pagamento	Dim_Procedimento
Fato Autorizações Cirúrgicas	X	X	X		X
Fato Faturamento & Contas	X	X	X	X	X
Fato Sinistralidade Consolidada	X	X	X	X	X

INSIGHT EXECUTIVO

Insight Executivo: Com dimensões conformadas, o cálculo da taxa de sinistralidade é inequívoco: qualquer diretoria que consultar obtém rigorosamente a mesma verdade contábil!

A Alternativa Ágil: Data Vault 2.0 (Dan Linstedt)

- **Projetado para Agilidade Máxima:** Suporta fusões, aquisições e mudanças diárias em sistemas legados.
- **Os 3 Blocos: Hubs** (chaves de negócio), **Links** (relações N:M) e **Satellites** (contexto histórico auditável).



Vantagem Executiva: *Auditoria 100% inviolável. Se a Omnivita adquirir um novo hospital amanhã, basta plugar novos satélites sem alterar tabelas existentes!*

Matriz Comparativa Canônica dos Paradigmas de DW

Critério Arquitetural	Bill Inmon (CIF / Top-Down)	Ralph Kimball (DDW / Bottom-Up)	Data Vault 2.0 (Hubs/Links/Sats)
Ponto de Partida	Modelo Entidade-Relacionamento Corporativo (3FN)	Processos de Negócio em Modelagem Dimensional	Chaves de Negócio atômicas (*Hubs*) e Hash Keys
Velocidade de Entrega	**Lenta** (meses a anos de planejamento prévio)	**Rápida** (entregas iterativas por processo de negócio)	**Média**/**Rápida** (modular, excelente para times ágeis)
Facilidade de Uso (BI/SQL)	**Baixa** no núcleo (exige Data Marts dependentes)	**Máxima** (Star Schema intuitivo para analistas de dados)	Requer camada de consumo dimensional posterior
Resistência a Mudanças	**Rígida** (alterar o núcleo afeta toda a estrutura)	**Moderada** (fácil adicionar novas dimensões e fatos)	**Altíssima** (novos atributos = novos satélites independentes)
Custo de Manutenção	Alto (requer comitê centralizado permanente)	Baixo/Médio (se a Bus Matrix for respeitada)	Médio (maior número de tabelas; exige automação)

Veredito para o Caso Omnivita: *O modelo de* ***Ralph Kimball com Bus Matrix padronizada*** *é a escolha ideal para unificar as métricas de curto prazo, podendo adotar princípios de* ***Data Vault*** *na integração forense.*

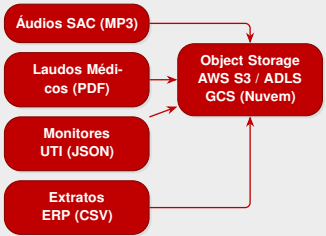
A Explosão dos Dados Não Estruturados e o Data Lake

O Gargalo do DW Tradicional:

- **Schema-on-Write:** o dado só entra se tiver estrutura relacional perfeita prévia.
- Custo histórico: US$ 10k a US$ 30k por Terabyte.
- Incapaz de guardar áudios, PDFs e telemetria.

O Nascimento do Data Lake (Object Storage):

- AWS S3, Azure ADLS, Google Cloud Storage.
- Custo despenca para $<$ **US$ 20/TB/mês**!
- **Schema-on-Read:** armazena bruto imediatamente; estrutura só na consulta.



A Promessa: *Armazenamento ilimitado e elástico para democratizar a Ciência de Dados e IA.*

A Patologia do Pântano de Dados (Data Swamp)

Na Omnivita: Dois anos após gastar R$ 12 milhões em Object Storage, o lago virou um lixão digital inauditável.

1. **Ausência de Propriedades ACID:** Falhas de rede gravam arquivos parciais corrompidos no bucket.
2. **Impossibilidade de Updates/Deletes:** Object Storage é imutável. Como atender à LGPD no meio de 50.000 arquivos Parquet?
3. **Ausência de Metadados e Catálogo:** Ninguém sabe a autoria, versão ou regra aplicada aos dados.
4. **Degradação de Performance:** O *Small Files Problem* destrói consultas de BI e explode os custos na nuvem.

Armadilha de Mercado: *Armazenamento barato sem governança transacional não é estratégia de dados; é* ***coleção de passivos jurídicos e financeiros****!*

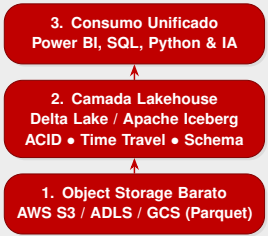
A Revolução do Data Lakehouse

A Síntese Dialética:

- Une o **baixo custo e flexibilidade** do Lake à **confiabilidade ACID** do Data Warehouse.

Como Opera na Prática?

- Dados em arquivos colunares abertos (**Apache Parquet**) no Object Storage barato.
- **Formatos Abertos de Tabela**: **Delta Lake**, **Apache Iceberg** ou **Apache Hudi**.
- Traz ACID, Time Travel e governança sobre o storage barato.



Definição Executiva: *Elimina a duplicação entre Lake e DW:* ***uma única cópia governada*** *serve a analistas de BI e cientistas de dados!*

Transações ACID e Time Travel no Lakehouse

Garantias ACID no Lakehouse:

- **Atomicidade:** Grava 100% ou nada. Fim dos arquivos corrompidos pela metade!
- **Consistência:** *Schema Enforcement* barra dados incorretos na entrada.
- **Isolamento:** Leituras analíticas não bloqueiam cargas de dados simultâneas.
- **Durabilidade:** Registro em Log de Transações (*Write-Ahead Log*).

Conformidade com a LGPD:

- Permite `DELETE` e `MERGE` pontuais com histórico auditável.

Viagem no Tempo (*Time Travel*):

- Consulta o estado exato em qualquer timestamp passado:

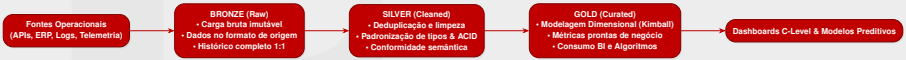
SQL – Consulta com Time Travel

```
SELECT SUM(valor_sinistro)
FROM faturamento_lakehouse
TIMESTAMP AS OF '2026-03-27 18:00:00';
```

INSIGHT EXECUTIVO

Insight Executivo: Resolve auditorias externas (PwC, ANS): prove exatamente quais dados embasaram o balanço em qualquer data!

A Arquitetura Medallion: Bronze, Silver e Gold



- **Camada Bronze (Bruta):** Preserva a evidência forense original. Se uma regra de transformação mudar, a fonte nunca é perdida.
- **Camada Silver (Confiável):** Tabelas enriquecidas e limpas. É o "Data Warehouse Corporativo" sob controle ACID.
- **Camada Gold (Estratégica):** Esquemas dimensionais (Kimball Star Schema). Cálculo oficial da Sinistralidade em sub-segundos.

Big Data Desmistificado: Os 5 V's Sob a Ótica de Negócios

- **Big Data não é sobre ter "muitos terabytes"; é sobre ultrapassar os limites da infraestrutura tradicional.**

Os 5 V's Clássicos	Significado Técnico de Engenharia	Impacto Estratégico de Negócios
1. Volume	Os dados não cabem no disco nem na RAM de 1 servidor.	Exige computação distribuída em cluster (*Cluster Computing*).
2. Velocidade	Dados chegam a taxas superiores à escrita em disco.	Exige arquiteturas de fluxo contínuo em tempo real (*Streaming*).
3. Variedade	Formatos não relacionais (áudio, imagens médicas, JSON).	Exige Object Storage e camadas abertas de abstração (Lakehouse).
4. Veracidade	Inconsistências, ruídos e transações duplicadas.	Exige validações automáticas de qualidade na Camada Silver.
5. Valor	A razão de existir de toda a arquitetura de dados!	Transformar dados brutos em margem operacional e mitigação de risco.

- **Computação Distribuída (Divisão e Conquista):**
  - *Escala Vertical (Scale-Up):* Máquina gigante de alto custo → Limite físico e custo exponencial.
  - *Escala Horizontal (Scale-Out):* Máquinas de nuvem coordenadas por motores distribuídos (**Apache Spark**) → Elasticidade infinita e resiliência!

A Batalha da Latência: Batch vs. Streaming

- **A Metáfora Fundamental dos Paradigmas de Processamento de Dados:**



Conceito de Ouro: *Batch é sobre eficiência de volume em lote sob demanda; Streaming é sobre agir antes que o valor da informação se evapore!*

Trade-Offs Econômicos e Operacionais da Latência

Dimensão Crítica	Processamento em Lote (*Batch*)	Processamento em Tempo Real (*Streaming*)
Latência Típica	Horas a dias (rotina noturna / Airflow)	Milissegundos a segundos (*Near Real-Time*)
Custo de Infraestrutura	**Baixo:** Servidores provisionados sob demanda	**Alto:** Cluster ativo 24h/dia, 7 dias/semana
Complexidade Técnica	Baixa: pipelines idempotentes simples com `dbt`/Airflow	Alta: tratamento de eventos fora de ordem e *watermarks*
Casos de Uso Típicos	Fechamento contábil, conciliações e relatórios fiscais	Bloqueio de fraudes, alertas de UTI e cotações dinâmicas

Regra de Decisão: *Só pague o alto custo do streaming quando a latência de horas gerar prejuízo financeiro ou operacional irreparável!*

O Rombo de R$ 8,4 Milhões: A Cegueira do Batch

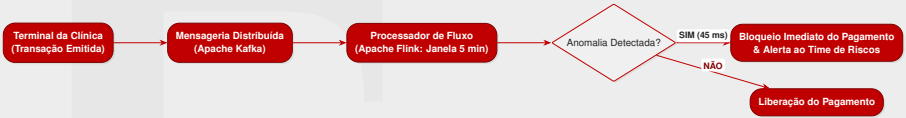


Detecção e Interrupção Instantânea de Fraude em Streaming (Kafka + Flink)

- **O Que Aconteceu no Feriado?**
  - O pipeline batch noturno só consolidava dados às 01h00 do primeiro dia útil seguinte.
  - Quadrilha emitiu R$ 8,4 milhões em exames falsos em 18 clínicas fantasmas: liquidação antes do primeiro alerta do Airflow!
- **A Solução em Tempo Real:** Arquitetura Orientada a Eventos (*Event-Driven*) com detecção analítica em menos de 50 milissegundos.

Topologia de Streaming Antifraude (Kafka + Flink)

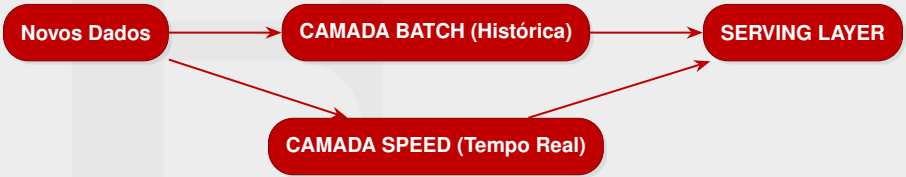
- **A Regra de Janela Deslizante (*Sliding Window*):**
  - *"O mesmo cartão realizou faturamento em 3 clínicas a mais de 200 km em menos de 15 minutos?"*



Retorno sobre o Investimento (ROI): *A esteira de streaming custaria R$ 400 mil/ano. Teria se pago* ***21 vezes em um único final de semana****!*

Arquiteturas Híbridas: O Dilema de Nathan Marz (Lambda)

- **A Proposta Original (2011):** Unir a exatidão matemática do Batch histórico com a velocidade do Streaming recente.



REFLEXÃO ANALÍTICA & DILEMA DE NEGÓCIO

A Dor de Cabeça Executiva: Código Duplicado. Regras de negócio precisam ser escritas e testadas duas vezes (Java/Flink para speed e SQL/dbt para batch). Manutenção dobrada!

Arquitetura Kappa: O Paradigma do Fluxo Contínuo Unificado

- **A Proposta de Jay Kreps (Criador do Apache Kafka):**
  - *"O processamento em lote é apenas um caso especial de streaming sobre dados passados."*
  - **Tudo na organização é um fluxo contínuo de eventos.** O passado é apenas um fluxo já registrado.



Vantagem Executiva: *Uma única base de código para manter, testar e evoluir. Se a regra de negócio mudar, basta reprocessar o log histórico (Stream Replay)!*

Simulação Executiva: Comitê de Arquitetura & Decisão Estratégica

- **O Desafio da Banca Consultiva (Equipes de 4 a 5 consultores):**
  - Vocês assumiram como Conselheiros de Dados da **Omnivita Saúde & FinTech**. O Conselho liberou CAPEX corporativo.
- **As 3 Decisões Mandatórias a Entregar no Pitch (3 min):**
  1. **Unificação Métricas:** Camada Gold com Kimball e Dimensões Conformadas (eliminar conflito 81,4% vs 73,2%).
  2. **Resgate do Lake (R$ 12M):** Arquitetura Medallion + Lakehouse (Delta/Iceberg) com ACID e LGPD.
  3. **Antifraude:** Batch, Lambda ou Kappa para auditoria transacional em tempo hábil?

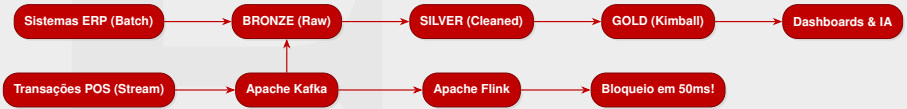
Diretriz de Avaliação: *A Banca atuará como Comitê de Riscos Corporativos, avaliando trade-offs de OPEX, Latência vs. Risco Financeiro e Governança, reprovando complexidade técnica sem ganho financeiro!*

Matriz Canônica de Decisão Arquitetural Corporativa

Arquitetura / Repositório	Latência Típica	Custo Operacional (OPEX)	Complexidade de Manutenção	Caso de Uso de Negócio Recomendado
Data Warehouse Tradicional (Kimball Star Schema)	Horas / Diário	Médio	Baixa a Média	Relatórios gerenciais e BI departamental baseado estritamente em dados relacionais estruturados.
Data Lake Tradicional (Object Storage Puro)	Minutos a Horas	Muito Baixo	Alta (Risco de *Data Swamp*)	Armazenamento de arquivo morto, logs brutos e dados não estruturados sem necessidade de transações ACID.
Data Lakehouse (Delta / Iceberg + Medallion)	Segundos a Horas	Médio / Baixo (Altíssimo ROI)	Média	**Padrão Moderno da Indústria:** Unifica BI analítico (Gold) e Ciência de Dados/IA sobre o mesmo storage com ACID e Time Travel.
Pipeline Batch (ELT com Airflow + dbt)	Diário / Turno	Baixo	Baixa	Fechamentos contábeis, cálculo de bônus, relatórios fiscais da ANS e processos sem criticidade de tempo real.
Streaming em Tempo Real (Kafka + Flink / Kappa)	Milissegundos	Alto (Cluster 24x7)	Alta	Detecção de fraudes, alertas clínicos de UTI em tempo real, precificação dinâmica e auditoria de alta criticidade.

Regra de Ouro do Arquiteto: *A melhor arquitetura não é a que usa as ferramentas mais caras ou complexas da moda, mas a que resolve o problema do negócio com a* ***menor complexidade operacional possível****!*

Síntese da Arquitetura Moderna de Dados Corporativa



- **A Síntese da Indústria:**
  1. **80% do Negócio** roda perfeitamente na esteira Batch/Lakehouse (menor custo e alta confiabilidade);
  2. **20% de Alta Criticidade** (fraudes, vidas) roda na esteira Streaming em tempo real.

Exit Ticket & Verificação de Aprendizagem Conceitual

- **Checagem Rápida de Domínio Cognitivo:**
  1. *Por que Ralph Kimball entrega valor mais rápido do que Bill Inmon?*
     - **Resposta:** Kimball é *bottom-up* e modular por processo de negócio; Inmon exige modelo 3FN centralizado prévio.
  2. *Como o Lakehouse (Delta/Iceberg) protege contra o Data Swamp e atende à LGPD?*
     - **Resposta:** Introduz ACID atômico sobre Object Storage e viabiliza `DELETE`/`UPDATE` com versionamento temporal (*Time Travel*).
  3. *Qual critério financeiro determina a escolha entre Batch ou Streaming?*
     - **Resposta:** A taxa de perda de valor da decisão. Se o atraso de horas gera prejuízo irrecuperável, o streaming justifica o cluster 24x7.

Síntese de Maestria: *Vocês consolidaram a visão estratégica e arquitetural dos maiores Chief Data Officers do mercado!*

Próxima Parada: Governança, Metadados e LGPD na Prática!

Próxima Parada: A Fronteira da Governança e Ética de Dados

Conectando Arquitetura a Conformidade Regulatória, Catálogo e Linhagem

- Construímos uma arquitetura de dados poderosa, resiliente e moderna.
- **Mas surgem os dilemas regulatórios e de governança:**
  - *Como auditar a origem de cada coluna que alimenta o dashboard do Diretor Médico? (Linhagem de Ponta a Ponta)*
  - *Como automatizar o consentimento e a anonimização de dados sensíveis exigidos pela LGPD?*
  - *Como manter um Catálogo de Dados vivo onde analistas encontram qualquer tabela em menos de 30 segundos?*

Na Aula 11: *Governança de Dados Corporativa, Catálogos de Metadados Ativos, Linhagem de Ponta a Ponta e LGPD na Prática!*

Obrigado pela dedicação e até a próxima aula!

Prof. Dr. Wagner Perin | FUCAPE Business School — 2026